

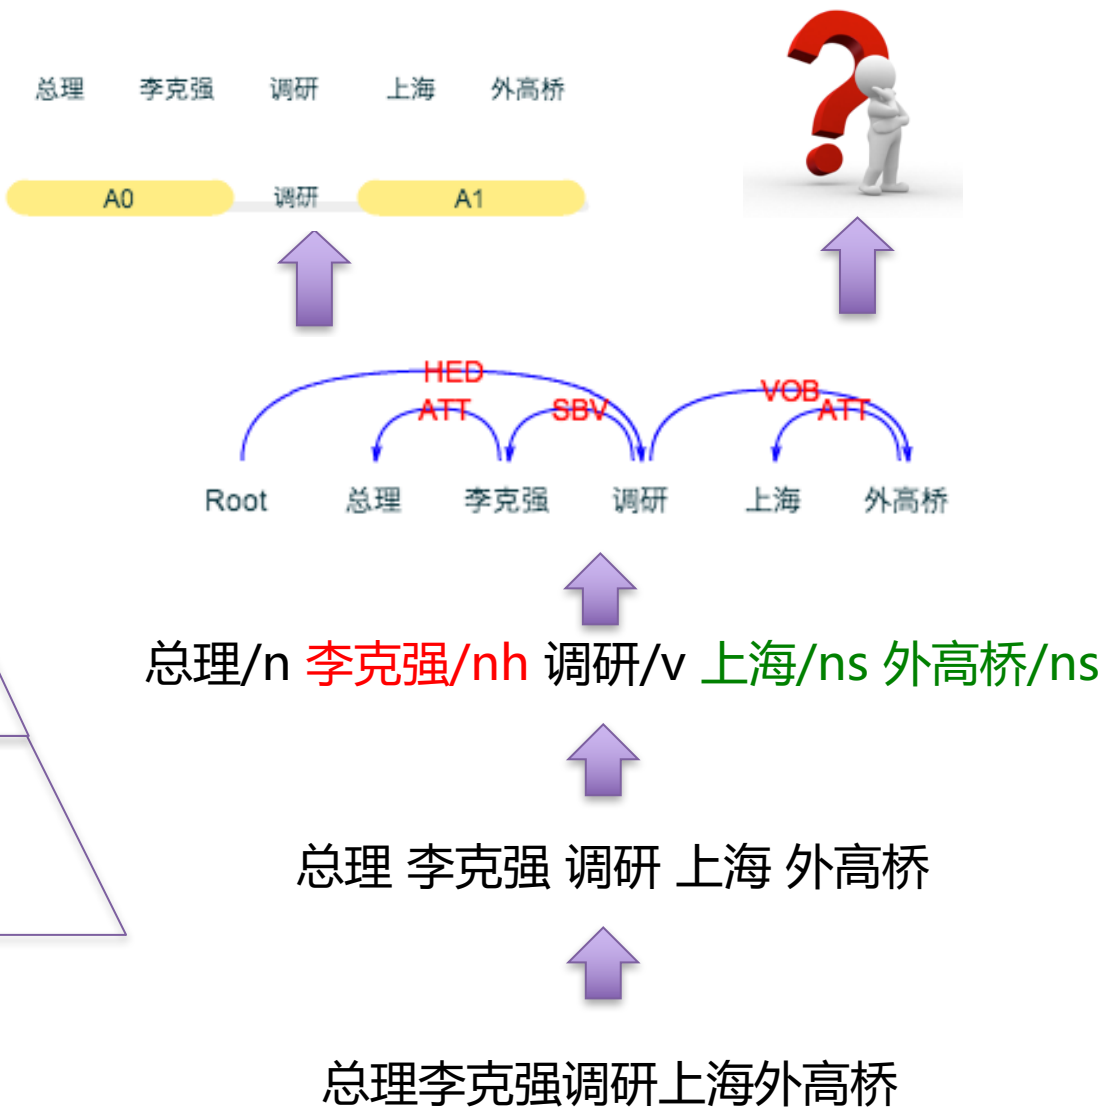
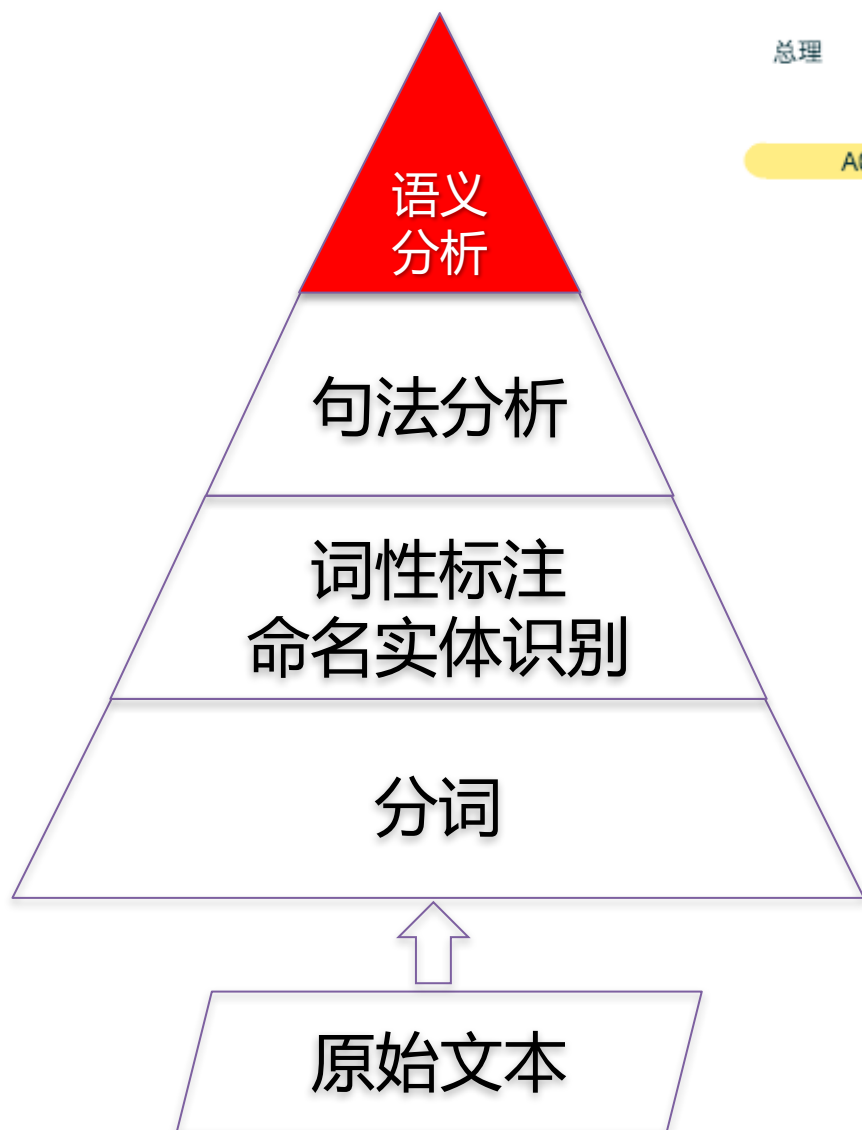
# 语义依存分析

车万翔

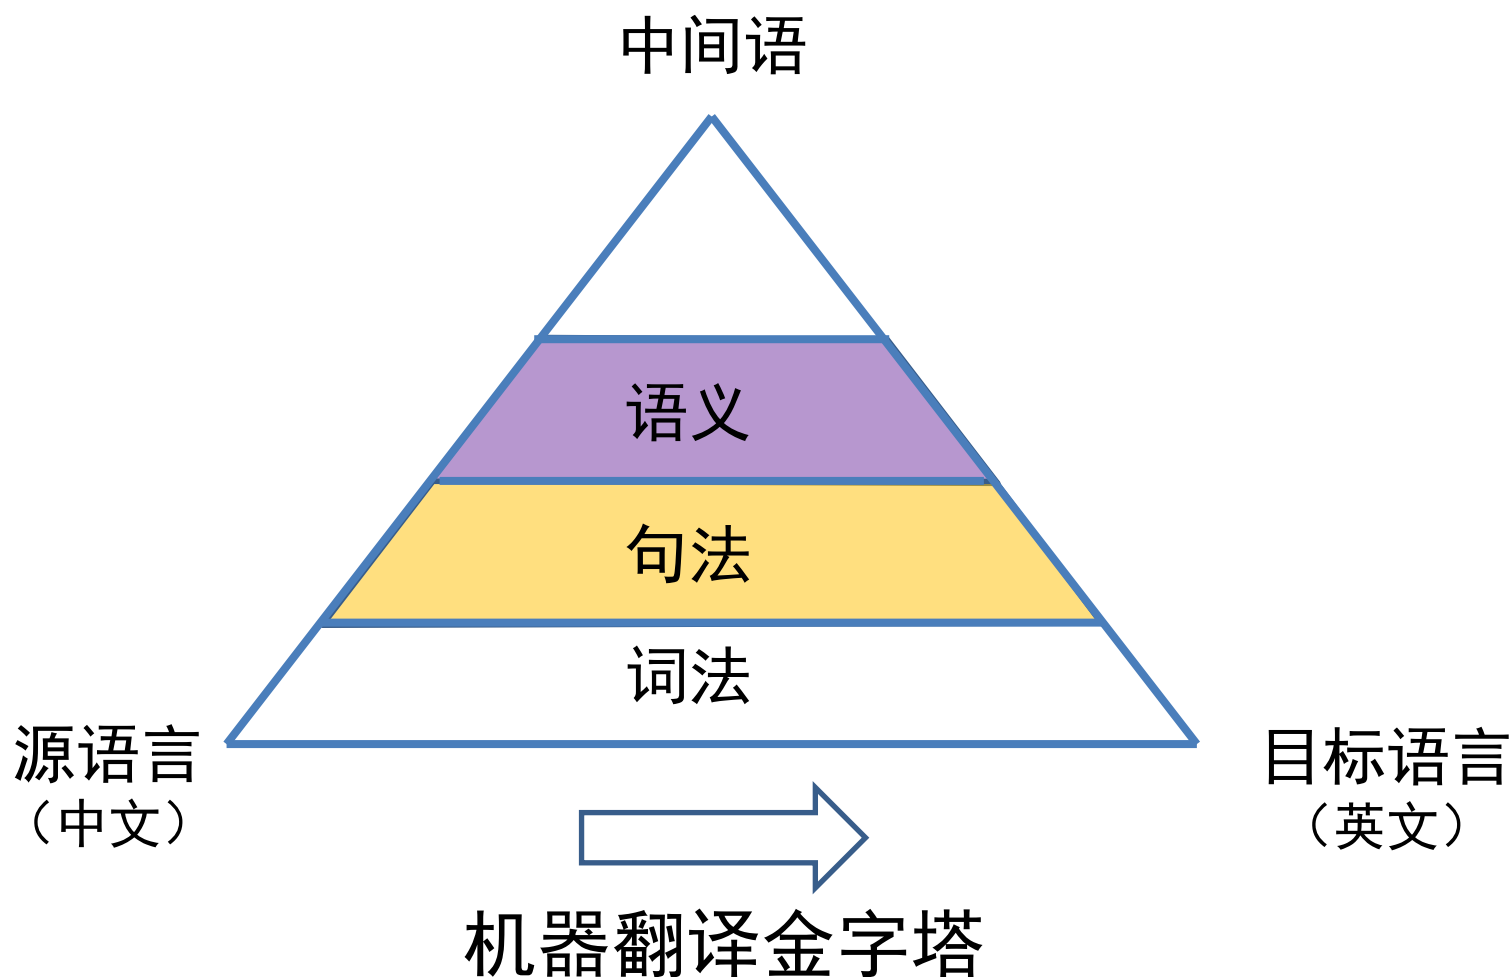
社会计算与信息检索研究中心

2017年春季学期

# 语言分析任务



# 分析得越深，转换的代价越小




# 句法分析

- 将输入文本从**序列形式**转化为**树状结构**，刻画句子内部的句法关系，是自然语言处理的核心问题


- 常见的句法关系

– 主、谓、宾、定、状、补、...




- 句法歧义

– 如：“喜欢乡下的孩子”



# 依存句法分析

- 形式简洁，易于理解和应用，是句法分析最主要的形式
- 词对之间由不对称的依存关系连接，形成树状语法结构
  - 箭头从核心词指向修饰词，弧上标记为依存关系类型
  - 约束条件
    - 唯一根节点
    - 单一父节点
    - 不对称
    - 无交叉



# 句法和语义

- 结构关系和构成成分不同



句子： 昨天 我 在教室里 给老师 写了一封 信

句法成分： 状语 主语 状语 状语 谓语 定语 宾语

语义成分： 时间 施事 处所 与事 动作 数量 受事

- 语义结构稳定，而句法结构随字面变化而变化

意思是语义成分永远是那么几个，但是这几个成分的位置一变，句法树就大变样了。



# 句法结构和语义关系不对应

- 句法结构相同，语义关系不同
  - 吃食堂 vs 买衣服
  - 我[施事]去过了 vs 北京[地点]去过了。
- 句法结构不同，语义结构相同
  - 打败敌人 vs 被敌人打败
  - 汤姆吃了苹果 vs 汤姆把苹果吃了

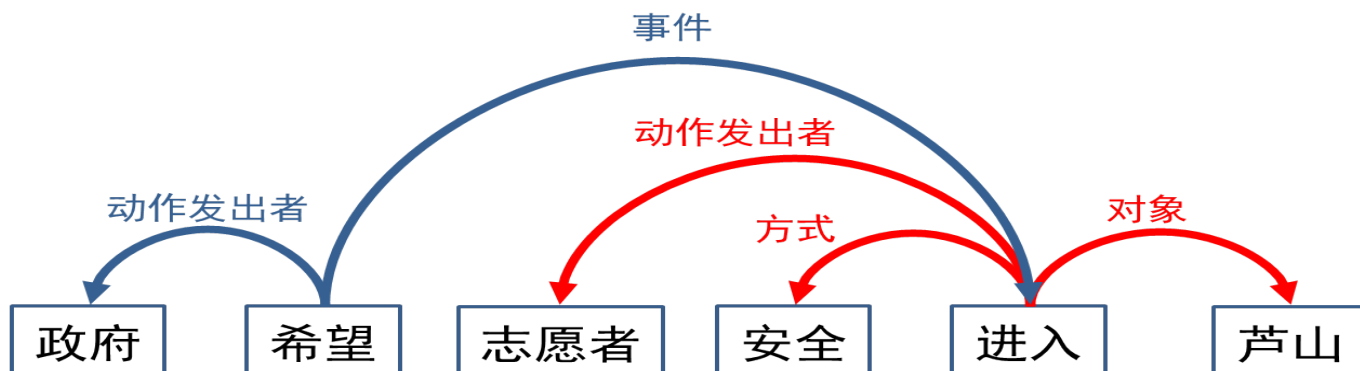
# 语义角色标注

- 论元（Argument）：和动词搭配的名词性成分
- 语义角色标注(Semantic Role Labeling, SRL)
  - 给定一个句子，分析该句中特定动词的论元结构，找出和特定动词搭配的论元并分析其语义角色
    - 例如：[施事张平]给了[与事李华][受事一本书]。
  - 核心角色：施事，受事，与事.....
  - 附属角色：地点，时间，行为方式，原因.....
- 语义角色标注是浅层语义分析的一种主要实现方式，是深层语义分析的简化和基础



# 语义依存分析

- 中文句子语义依存树
  - 融合了句子的依存结构和语义关系



- 语义依存关系不因句子表层形式而变化

张三吃了苹果

张三把苹果吃了

苹果被张三吃了

吃(张三, 苹果)

# 语义依存分析与语义角色标注的区别

|      | 语义角色标注                           | 语义依存分析     |
|------|----------------------------------|------------|
| 理论   | 谓词理论                             | 依存理论       |
| 结构   | 谓词-角色                            | 依存结构       |
| 焦点   | 主要谓词                             | 句子中每个词     |
| 对象   | 主要谓词及其论元                         | 所有核心词及其修饰词 |
| 标签   | 含义随不同谓词而变化<br>( Arg0-5 , ArgM- ) | 直接刻画具体含义   |
| 标签数量 | 少                                | 多          |
| 标注结果 | 主要谓词的语义角色树                       | 整个句子的完整依存图 |
| 关系转化 | 难                                | 易          |
| 包含关系 | --                               | 包含语义角色标注   |

# 相关语义体系与语料库

- 语义体系

- 董振东的“知网”、鲁川的“意合网络”
- 冯志伟的“论元结构”、袁毓林的语义体系、林杏光的“汉语基本格”

- 语料库

| 研究者                    | 语义理论   | 标注集                                 | 语料库                   | 语言   |
|------------------------|--------|-------------------------------------|-----------------------|------|
| [袁, 2008]              | 论元结构   | 23种论元                               | 新闻语料                  | 简体中文 |
| [Xue and Palmer, 2003] | 语义角色   | 语义角色(argN, N:1-5)和18种secondary tags | Penn Chinese Treebank | 简体中文 |
| [You and Chen, 2004]   | 语义角色   | 74 种不同的语义角色                         | Sinica Treebank       | 繁体中文 |
| [Li et al., 2003]      | 语义依存结构 | 59 种语义关系, 9 种句法关系, 2种特殊关系部分         | Tsinghua语料            | 简体中文 |
| [Yan, 2007]            | 语义依存结构 | 70种语义关系, 20种句法关系, 2种特殊标记            | Penn Chinese Treebank | 简体中文 |

# 汉语与英语的基本特点：存在显著差异

- **英语重形合，汉语重意合**，语法灵活，仅依靠句法信息而不充分利用语义关联，难以有效判断结构关系
- **英语句子理解的主流方法是“先句法后语义”，汉语呢？**

|        | 中文 | 英文 | 例子  |
|--------|----|----|---|
| 词语间隔   | 无  | 有  | 中国的经济发展<br>The development of China' s economy  |
| 形态变化   | 无  | 有  | 总理李克强 <b>调研</b> （动词还是名词？） 很深入<br>Premier Keqiang Li made a very in-depth <b>investigation</b><br>机器翻译，翻译人员，翻译小说<br><b>Machine Translation, Translator, Translated Novel</b> |
| 时态变化   | 无  | 有  | 我回家了. I <b>will go</b> home. / I <b>went</b> home.  |
| 句法形式   | 灵活 | 规范 | 你买 <b>票</b> 了么？ / <b>票</b> 你买了么？（Have you bought the ticket?）美国反恐为何越反越恐？  |
| 成分省略   | 多  | 少  | <b>（救治）</b> 很及时， <b>（伤者）</b> 情况比较好  |
| 复杂名词短语 | 多  | 少  | 中国北京红十字芦山抢险救援队“五一”节期间工作掠影   |

# 句法依存与语义依存的异同

- 相似之处
  - 都是以依存语法为理论基础
  - 为句子中的每个词标注依存关系
- 不同之处

## 句法依存


- ① 在依存弧中隐含谓词-论元结构
- ② 关系标签少（十个左右）
- ③ 从汉语语法角度描述主谓宾等结构
- ④ 依存树结构足够描述句法关系

## 语义依存

- ① 明确标出依存弧中谓词-论元之间的语义关系
- ② 关系标签多（几十或上百）
- ③ 以谓词论元指派为理论基础，以词对为单位刻画依存词对间的语义
- ④ 依存图才能完整刻画语义

# BH-SDP对语义关系的定义

- 北语-哈工大语义依存分析体系
  - BLCU-HIT Semantic Dependency Parsing (BH-SDP)
- 语义关系更精细
  - 123 种语义关系 ( 借鉴HowNet 84 种关系 ) vs. 20 种句法关系
- 有语义特色的依存结构
  - 反关系：动词作为名词的修饰语
  - 间接关系：核心词是动词化的名词
- 10,068 句子 ( 来源：CTB , Chinese TreeBank)

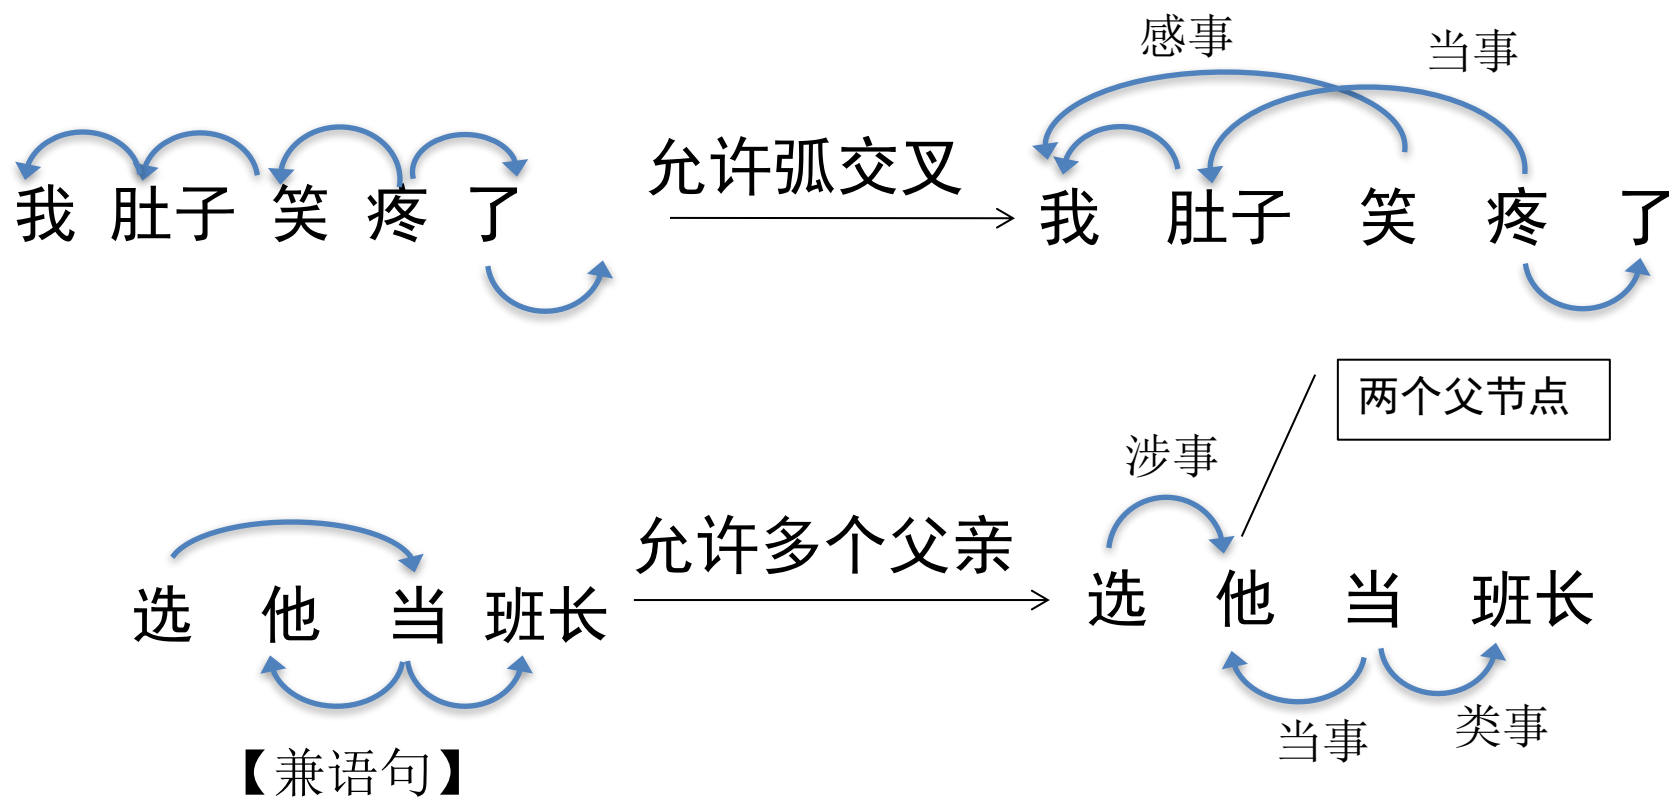


# BH-SDP-v1(2011)语料库的不足

- 有些语义关系彼此易混淆
- 语义关系数量太大，有些关系在标注语料中出现次数很少
- 句子全部来自新闻，涵盖的语言现象有限
- 依存树结构，刻画语义不全面

# 语义依存（图）分析

- 形式上类似于依存语法，但必要时突破树形结构
- 弧上标注的是“语义”关系





# 新版语义依存语料库

- 在BH-SDP-v1基础上，提出了一个新的语义依存体系BH-SDP-v2，压缩了语义关系类型的数量
- 从“语义依存树”到“语义依存图”，语

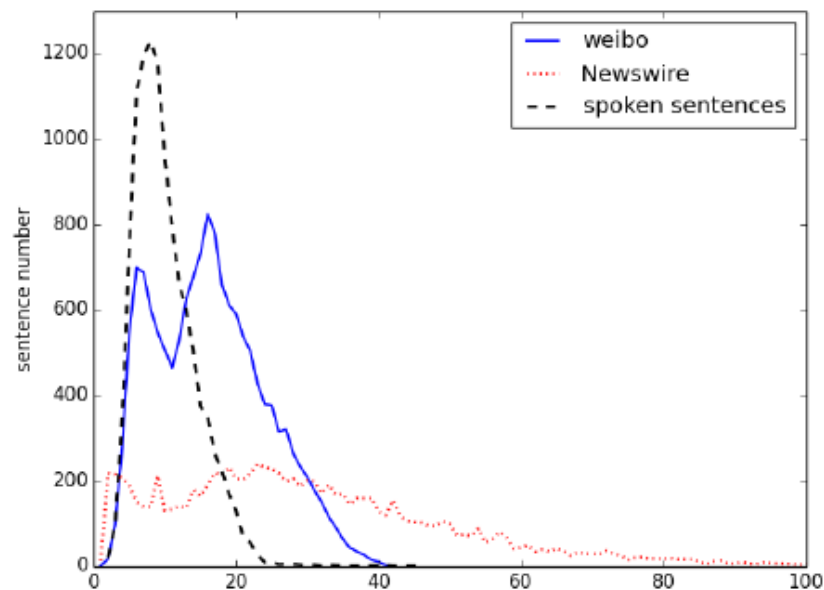
|      | BH-SDP-v1   | BH-SDP-v2 |
|------|---|-----------|
| 关系总数 | 123   | 98        |
| 主要区别 | v2重新组织了v1的语义关系，将关系分为主要语义角色，事件关系，关系标记，减少不必要的类间关系混淆 |           |

# 依存图库构建

- 语料描述

- 口语语料，新闻语料，微博语料
- 新闻语料来自Penn Chinese Treebank 6.01

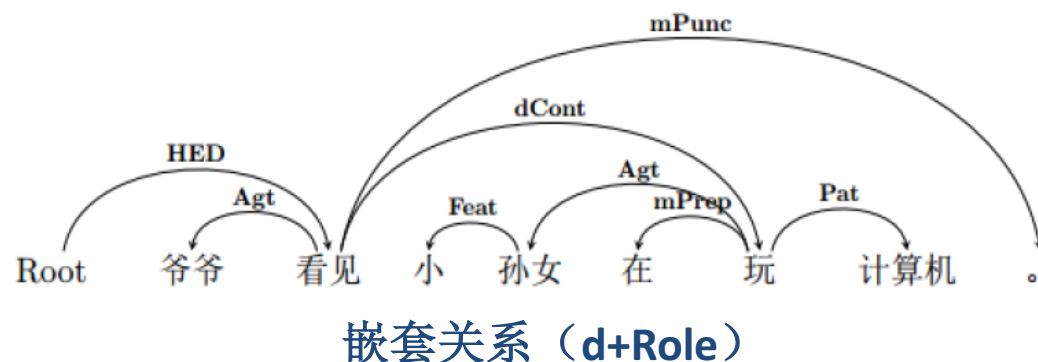

|    | 句子数   | 词数     | 句子平均长度 |
|----|-------|--------|--------|
| 口语 | 10038 | 101140 | 10.08  |
| 新闻 | 10068 | 308383 | 30.63  |
| 微博 | 10755 | 172080 | 16     |



句子数目在不同句子长度下的分布

# 语义标签

- 语义角色 ( 32种 )
  - 一般关系
  - 反关系 ( r+Role )
  - 嵌套关系 ( d+Role )
- 事件关系 ( 19种 )
- 语义标记 ( 16种 )



# 一般关系标签集合

---

## 周边论元

---

|      |   |
|------|---|
| 主体角色 | 施事 Ag、当事 Exp、感事 Aft、领事 Poss、                |
| 客体角色 | 受事 Pat、客事 Cont、成事 Prod、源事 Orig、与事 Datv      |
| 系体角色 | 属事 Belg、类事 Clas、依据 Accd                     |
| 情由角色 | 缘故 Reas、意图 Int、结局 Cons                      |
| 状况角色 | 方式 Mann、工具 Tool、材 Matl                      |
| 时空角色 | 时间 Time、空间 Loc、趋向 Dir、历程 Proc、范围 Sco        |
| 度量角色 | 数量 Quan、数量数组 Qf、频率 Scop、顺序 Seq              |
| 其他角色 | 特征 Feat、宿主 Host、名字修饰 Nmod、时间修饰 Tmod、比较 Comp |

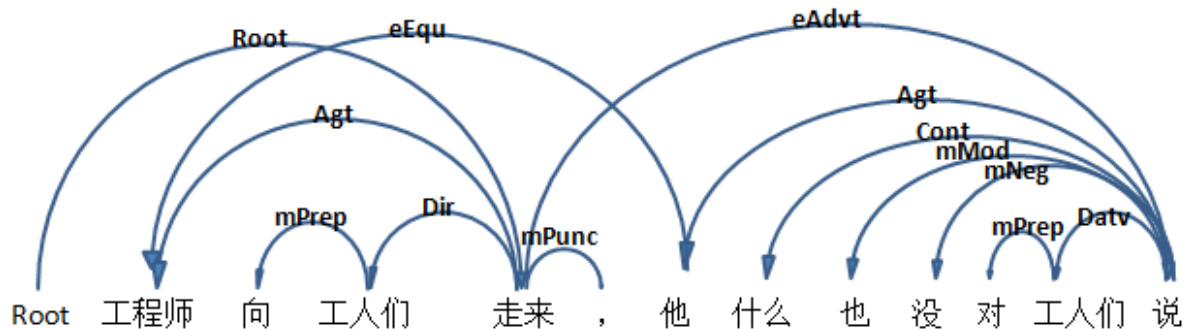
---

# 事件关系和语义标记

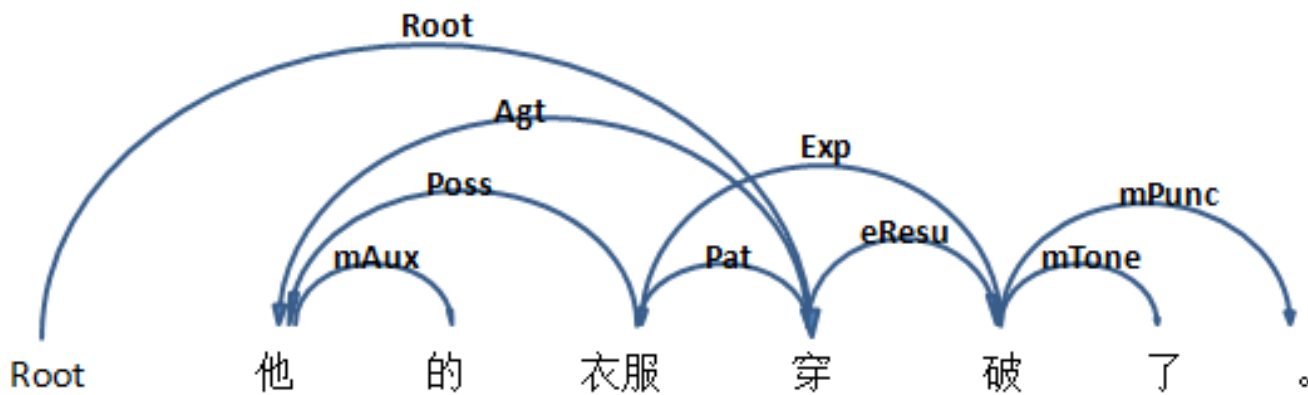
|      |   |
|------|---|
| 对称关系 | 并列关系 eCoo、选择关系 eSelt、等同关系 eEquv   |
| 接续关系 | 先行 EPrec、后继 ESucc、递进 EProg、转折 eAdvt、原因 eCau、结果 eRes、推论 eInf、条件 eCond、假设 eSupp、让步 eConc、手段 eMetd、<br>目的 ePurp、割舍 eAban、选取 ePref、总括 eSum、分叙 eRect |
| 语义标记 |   |
| 关系标记 | 连词标记 mConj、的字标记 mAux、介词标记 mPrep   |
| 依附标记 | 语气标记 mTone、时间标记 mTime、范围标记 mRang、程度标记 mDegr、频率标记 mFreq、趋向标记 mDir、插入语标记 mPars、否定标记 mNeg、<br>情态标记 mMod  |
| 其他   | 标点标记 mPunc、多数标记 mMaj、无实意 mVain、离合标记 mSepa   |

## “交叉弧” 典型句子举例

- A:代词指称

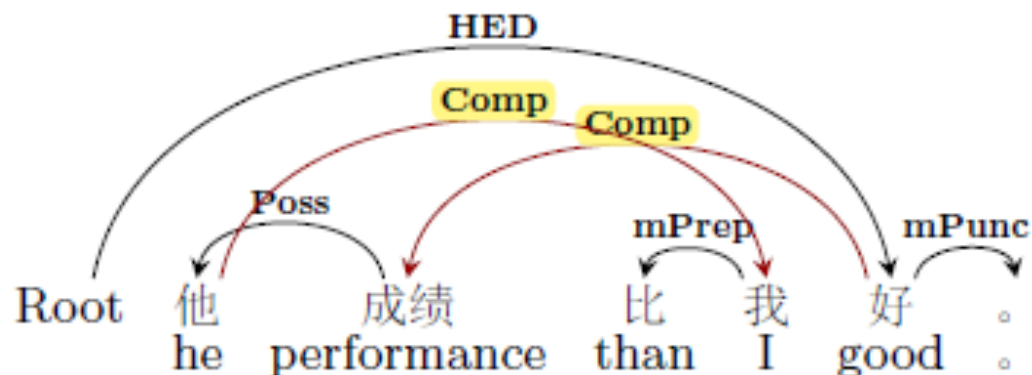


- B:动补谓语句

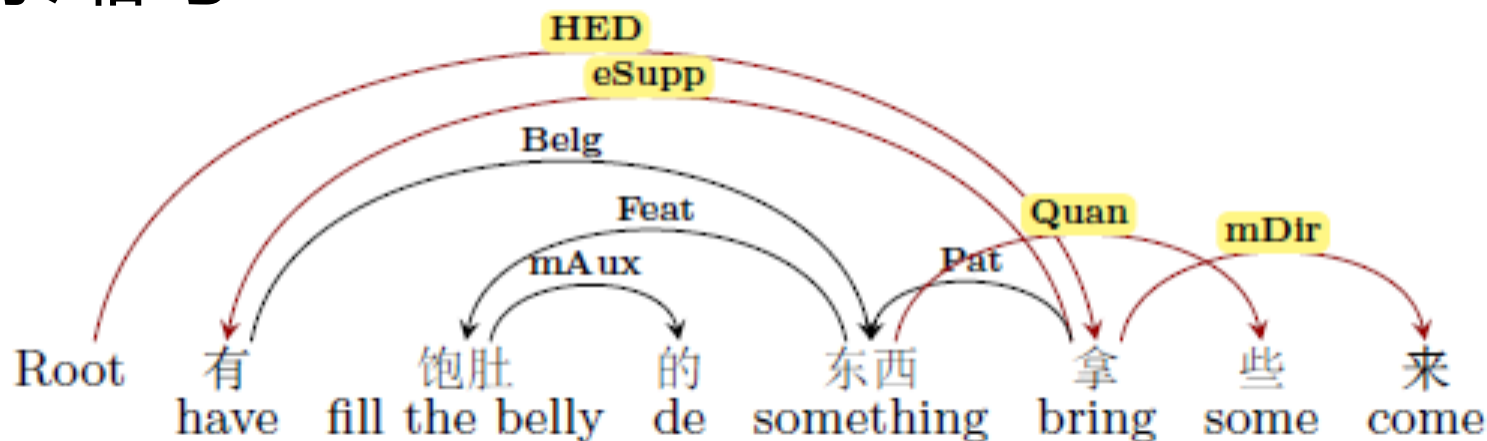


# “交叉弧” 典型句子举例

- C:比较句

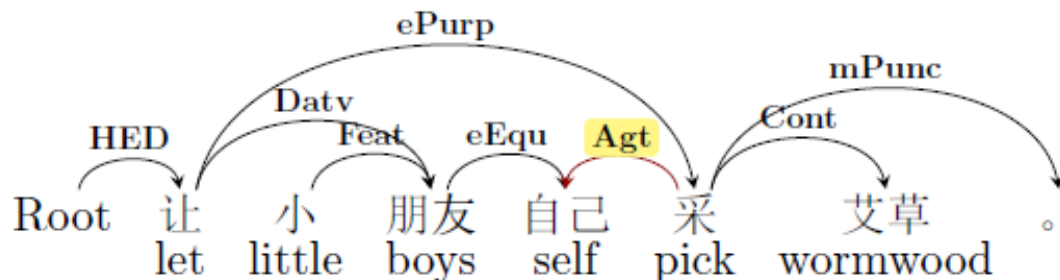


- D:紧缩句：




# “多父节点” 典型句子举例

- A:使动句：多父节点



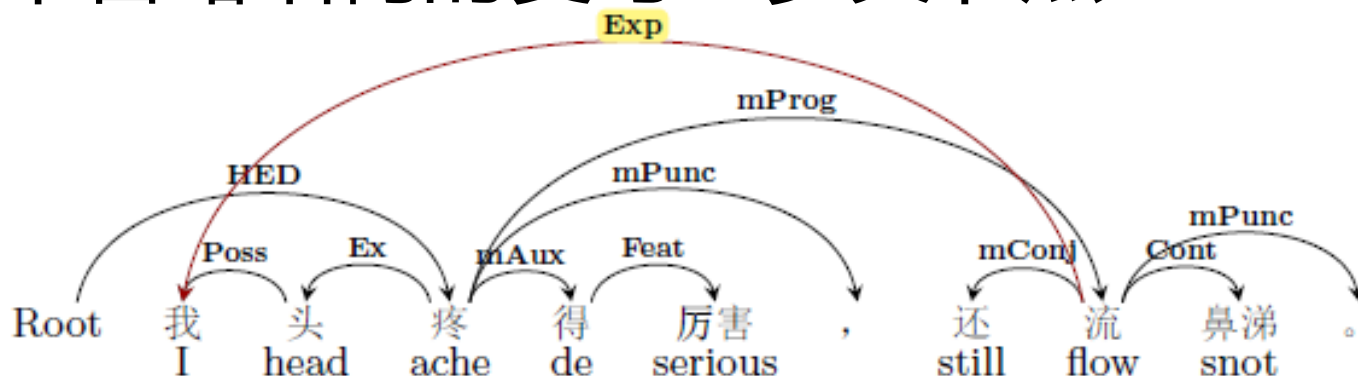
- B:多代词：多父节点



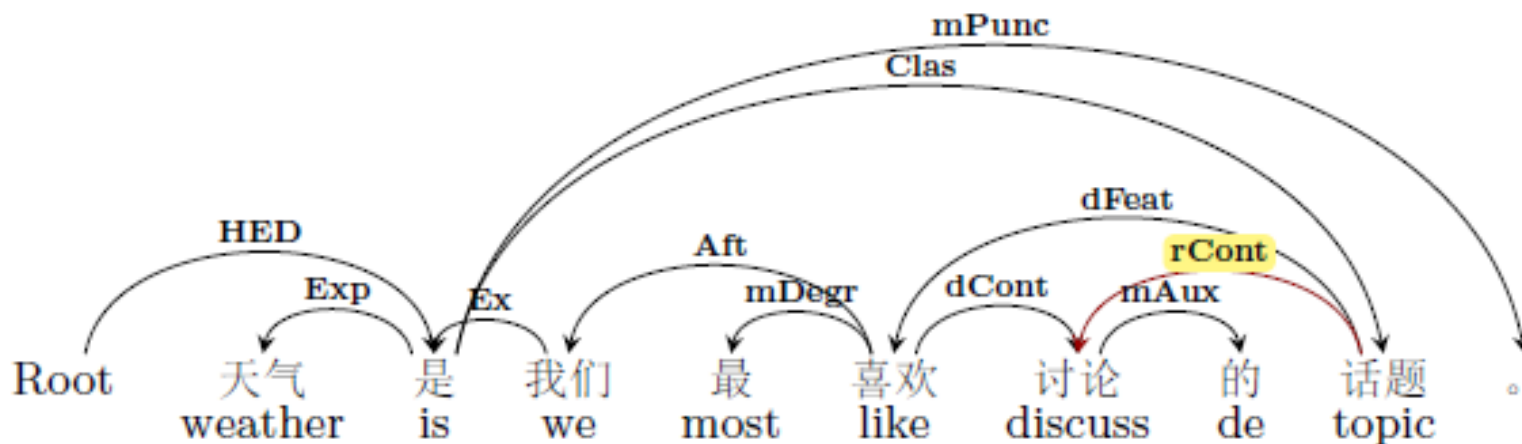


# “多父节点” 典型句子举例

- C:带省略结构的复句：多父节点



- D:动词短语做修饰语：多父节点




# 依存树与依存图的对比

| 依存树   | 依存图   |
|---|---|
| 一个句子中只有一个成分是独立的   | 一个句子中只有一个成分是独立的   |
| 其他成分直接依存于某一个成分  | 其他成分直接依存于某一个成分  |
| 任何一个成分都不能依存于两个或两个以上的成分                                      | 任何一个成分可以同时依存于两个或两个以上的成分                                       |
| 如果A成分直接依存于B成分，而C成分在句中位于A和B之间，那么C或者直接依存于B，或者直接依存处于A和B之间的某一成分 | 如果A成分直接依存于B成分，而C成分在句中位于A和B之间，那么C可以依存于A左边的成分或B右边的成分，即允许依存弧之间交叉 |
| 中心成分左右两边的其他成分互相不发生关系  | 只要中心成分左右两边的成分有语义关系就可以有依存弧连接                                   |

# 依存分析算法


# Dependency tree

- A dependency tree is a tree structure composed of the input words and meets a few constraints:
  - Single-head
  - Connected
  - Acyclic




# Projective dependency trees

- Informally, “**projective**” means the tree does not contain any **crossing arcs**.



# Non-projective dependency trees

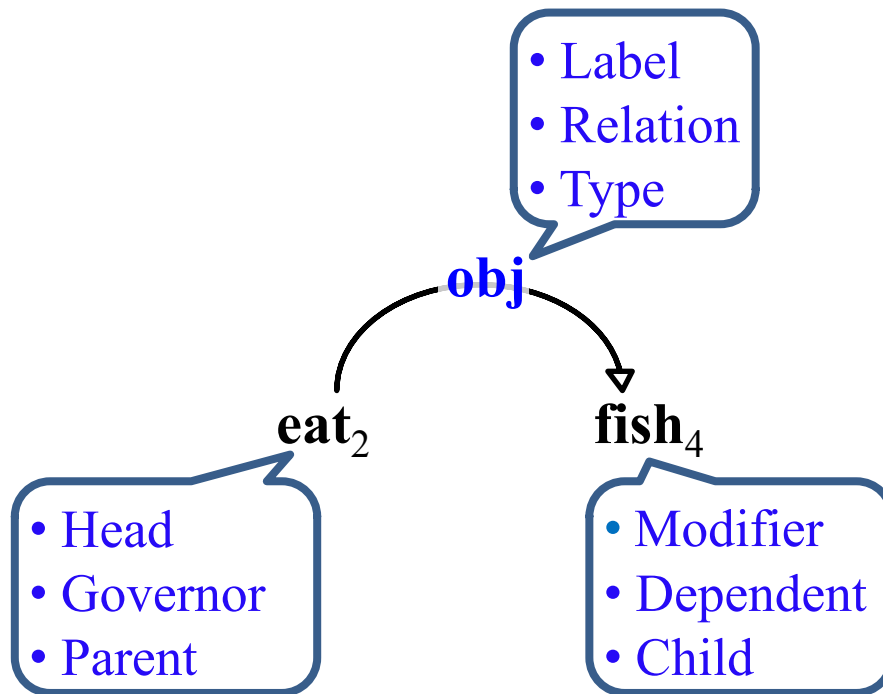
- A non-projective dependency tree contains crossing arcs.



Example from “Dependency Parsing” by Kübler, Nivre, and McDonald, 2009


# Dependency Tree

- The basic unit is a link (dependency, arc) from the head to the modifier.




# Evaluation Metrics

- Unlabeled attachment score (UAS)
  - The percent of words that have the correct heads
- Labeled attachment score (LAS)
  - The percent of words that have the correct heads and labels.
- Root Accuracy (RA)
- Complete Match rate (CM)





# Formalism of Dependency Parsing



$$Y^* = \arg \max_{Y \in \Phi(X)} \text{score}(X, Y)$$

$X = x_1 x_2 \dots x_n \rightarrow$  the input sentence

$(h, m) \rightarrow$  a link from the head  $x_h$  to the modifier  $x_m$

$Y = \{(h, m) : 0 \leq h \leq n, 0 < m \leq n\} \rightarrow$  a candidate tree


$\Phi(X) \rightarrow$  The set of all possible dependency trees over  $X$

# Supervised Approaches for Dependency Parsing

- Graph-based
- Transition-based
- Hybrid (ensemble)
- Other methods

# Graph-based Dependency Parsing


- Find the highest scoring tree from a complete dependency graph.



$$Y^* = \arg \max_{Y \in \Phi(X)} \text{score}(X, Y)$$

# Two problems


- The search problem
  - Given the score of each link, how to find  $Y^*$ ?
- The learning problem
  - Given an input sentence, how to determine the score of each link?  $\mathbf{w} \cdot \mathbf{f}$
  - How to learn  $\mathbf{w}$  using a treebank (supervised learning)?



$$Y^* = \arg \max_{Y \in \Phi(X)} score(X, Y)$$

# First-order as an example

- The first-order graph-based method assumes that the dependencies in a tree are independent from each other. (arc-factorization)




$$score(X, Y) = \sum_{(h, m) \in Y} score(X, h, m)$$

# Search problem for first-order model

- Eisner (2000) described a dynamic programming based decoding algorithm for bilexical grammar.
- McDonald+ (2005) applied this algorithm to the search problem of the first-order model.
- Time complexity  $O(n^3)$

# The learning problem


- Given an input sentence, how to determine the score of each link?



- Feature based representation: a link is represented as a feature vector  $\mathbf{f}(2,4)$

$$score(2,4) = \mathbf{w} \cdot \mathbf{f}(2,4)$$

# Features for one dependency

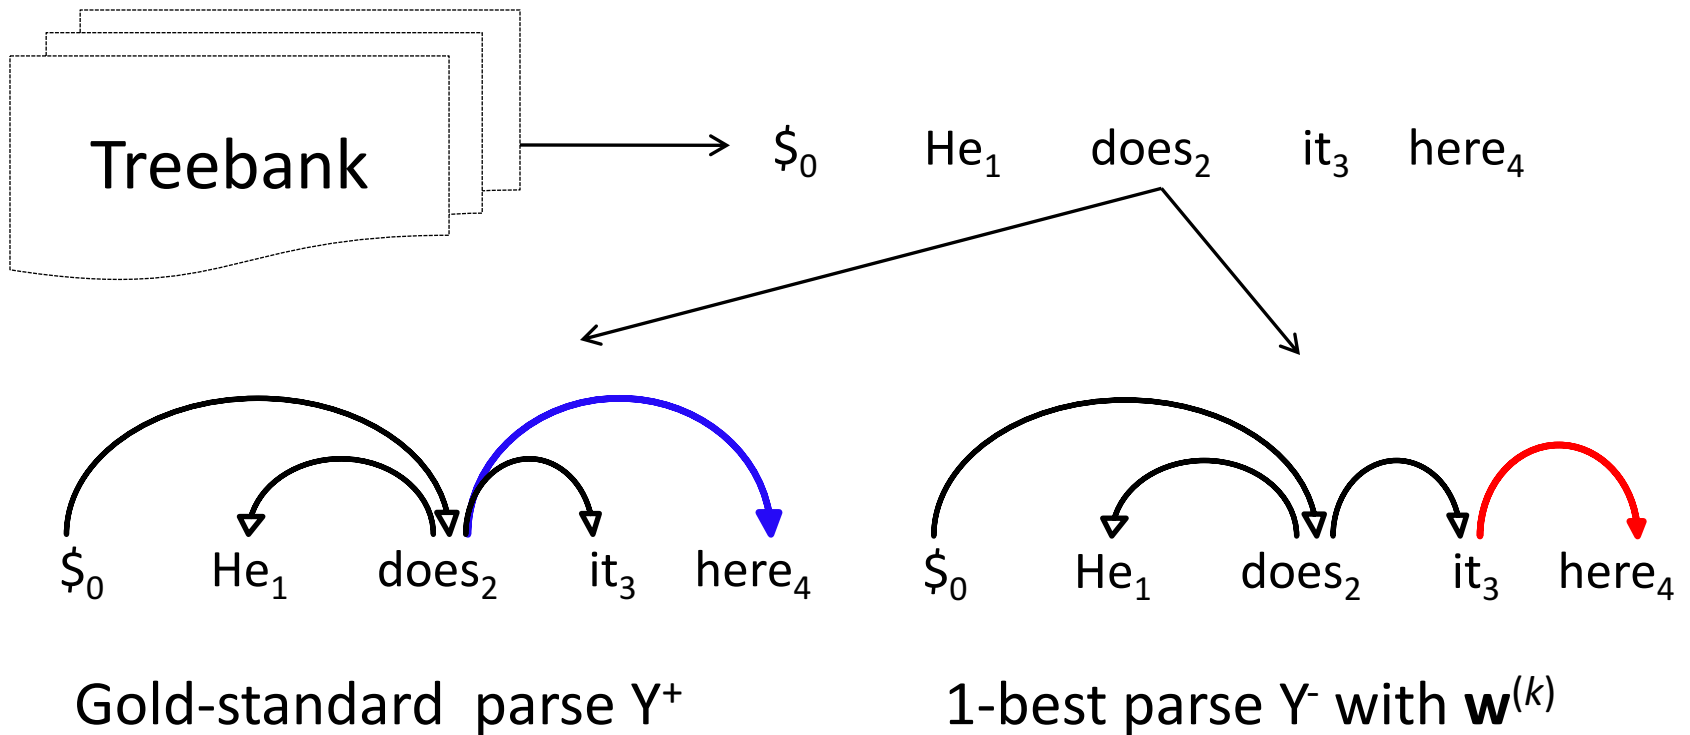




# How to learn $w$ ? (supervised)

- Use a treebank
  - Each sentence has a manually annotated dependency tree.
- Online training (Collins, 2002; Crammer and Singer, 2001; Crammer+, 2003)
  - Initialize  $\mathbf{w} = \mathbf{0}$
  - Go through the treebank for a few (10) iterations.
    - Use one instance to update the weight vector.

# Online learning w



$$\mathbf{w}^{(k+1)} = \mathbf{w}^{(k)} + \mathbf{f}(X, Y^+) - \mathbf{f}(X, Y^-)$$

# Transition-based Dependency Parsing

- Gradually build a tree by applying a sequence of transition actions. (Yamada and Matsumoto, 2003; Nivre, 2003)
- The score of the tree is equal to the summation of the scores of the actions.

$$score(X, Y) = \sum_{i=0}^m score(X, h_i, a_i)$$

$a_i$  → the action adopted in step  $i$

$h_i$  → the partial results built so far by  $a_0 \dots a_{i-1}$

$Y$  → the tree built by the action sequence  $a_0 \dots a_m$

# Transition-based Dependency Parsing

- The goal of a transition-based dependency parser is to find the highest scoring action sequence that builds a legal tree.

$$Y^* = \arg \max_{Y \in \Phi(X)} \textit{score}(X, Y)$$

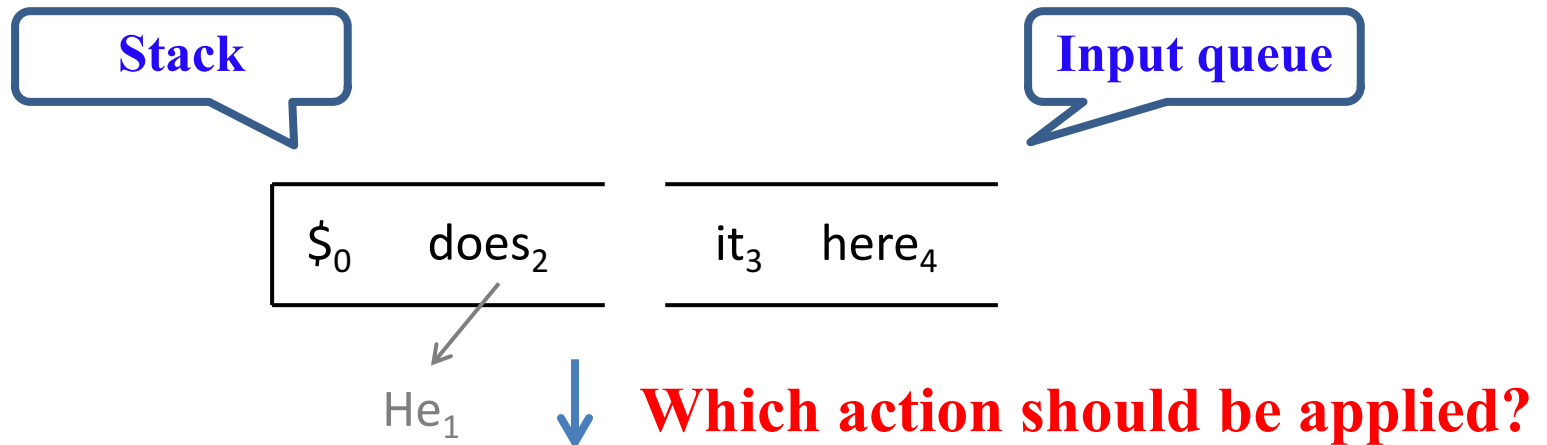
$$= \arg \max_{a_0 \dots a_m \rightarrow Y} \sum_{i=0}^m \textit{score}(X, h_i, a_i)$$

# Two problems for Transition-based Parsing

- The search problem
  - Assuming the model parameters (feature weights) are known, how to find the optimal action sequence that leads to a legal tree for an input sentence?
  - Greedy search as an example
- The learning problem
  - How to learn the feature weights?
  - Online training


# Components of Transition-based Parsing

- A stack to store the processed words and the partial trees
- A queue to store the unseen input words
- Transition actions
  - Gradually build a dependency tree according to the contexts (history) in the stack and the queue.

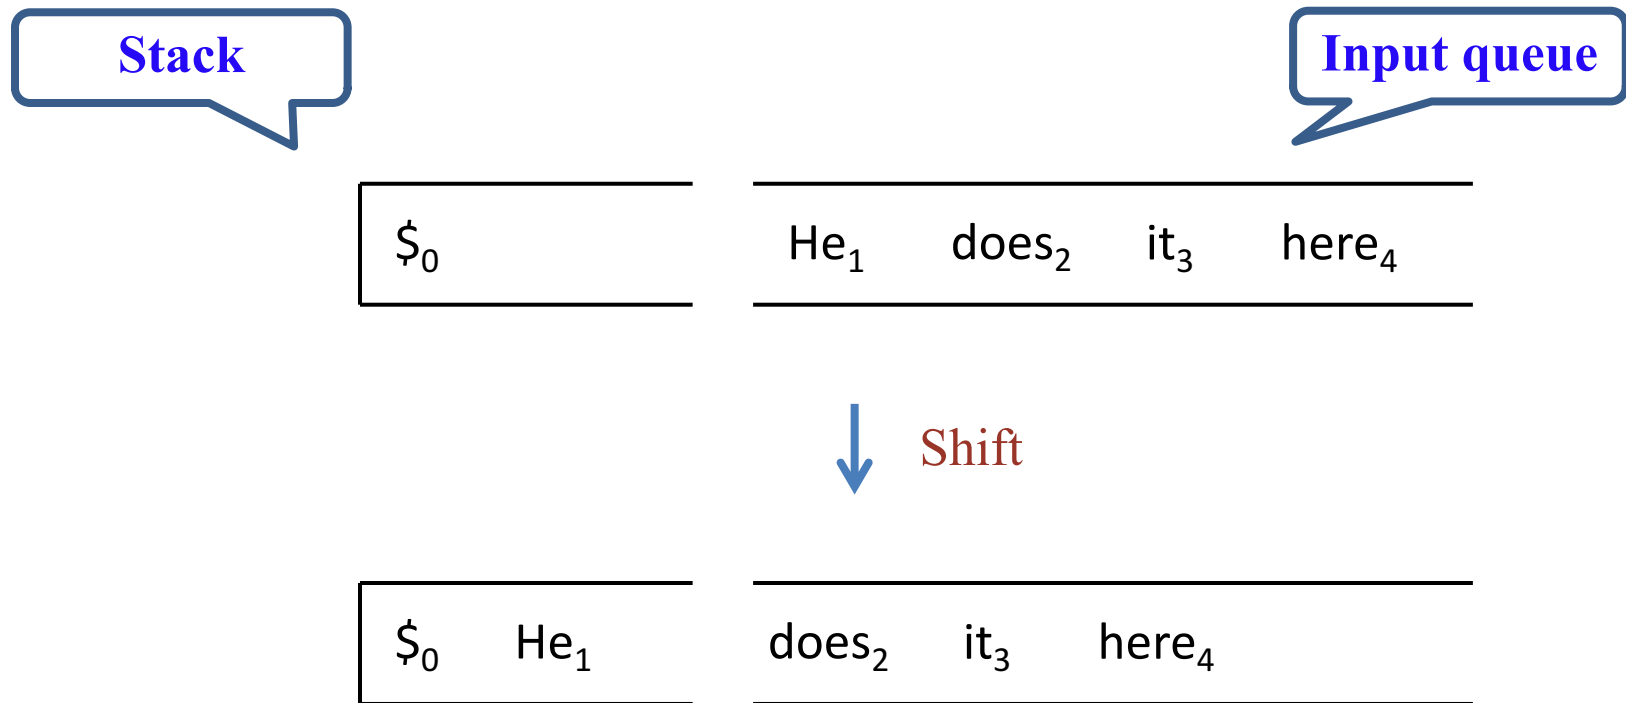


# An arc-eager transition-based parser

- Four actions
  - Shift
  - Left-arc
  - Right-arc
  - Reduce

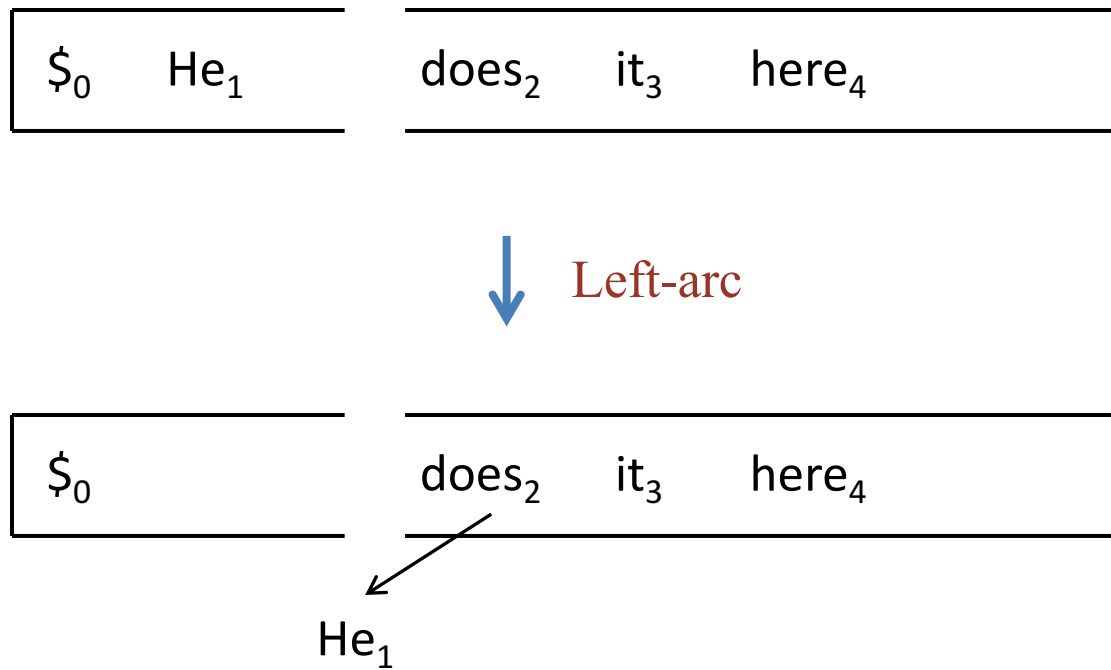


# An arc-eager transition-based parser

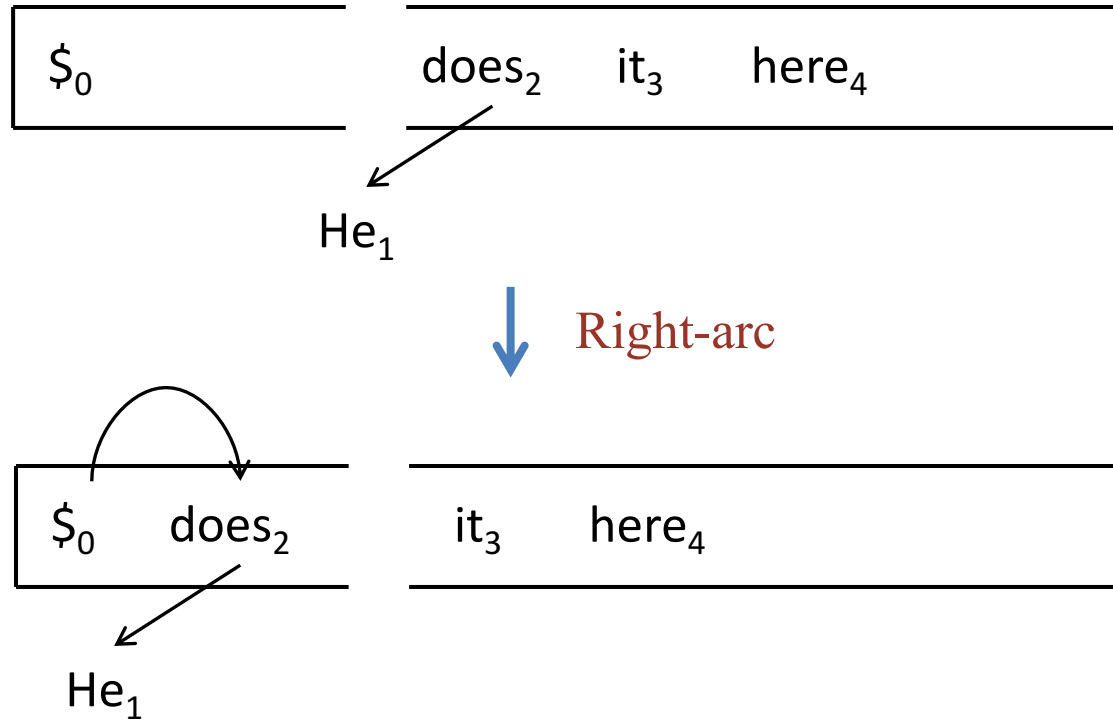




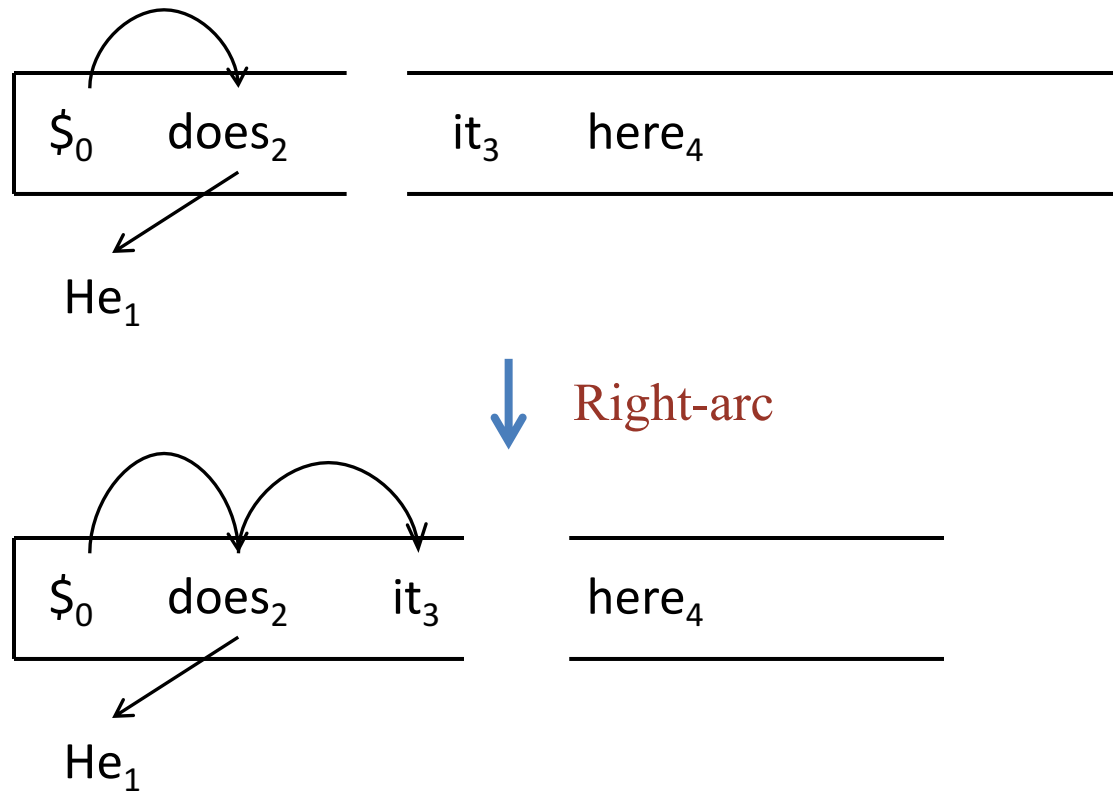
# An arc-eager transition-based parser




# An arc-eager transition-based parser




# An arc-eager transition-based parser




# An arc-eager transition-based parser




# An arc-eager transition-based parser




↓ Right-arc




# An arc-eager transition-based parser



# An arc-eager transition-based parser



↓ Reduce



**Complete!**